Implementação de Sistemas de Ficheiros

João Paulo

Grupo de Sistemas Distribuídos
Departamento de Informática
Universidade do Minho

Estrutura de sistemas de ficheiros

- Ficheiros:
  - unidade lógica de armazenamento
- Sistemas de ficheiros:
  - residem em armazenamento secundário (disco)
  - podem ser organizados em camadas
  - contém diversas estruturas de dados
  - gerem a alocação de espaço em disco
  - necessitam de gerir espaço livre

Organização em camadas

- Sistemas de ficheiros podem ser organizados em camadas
  - controlo de I/O: contém device drivers e interrupt handlers
    - comunica com os controladores dos dispositivos
  - sistema de ficheiros básico (block device): transmite comandos aos device drivers para ler e escrever blocos físicos em disco
  - módulo de organização de ficheiros:
    - conhece a disposição dos ficheiros em disco
    - traduz blocos lógicos dos ficheiros em blocos físicos
    - faz pedidos de transferência ao sistema de ficheiros básico
    - inclui o gestor de espaço livre em disco
  - sistema de ficheiros lógico:
    - manipula metadados do sistema de ficheiros:
    - manipula estrutura de directórios
    - manipula file control blocks
    - responsável por protecção no acesso aos ficheiros
- As duas camadas mais baixas podem ser partilhadas por diversos sistemas de ficheiros

Estruturas de um sistema de ficheiros

- boot control block: contém informação necessária ao arranque de um sistema operativo nesse volume
  - pode ser chamado de boot block ou partition boot sector
- volume control block: informação sobre o volume ou partição
  - número e tamanho dos blocos
  - número e apontadores para blocos livres
  - número e apontadores para file control blocks livres
- FCB –File control block: estrutura com informação sobre ficheiro; inode em Unix
  - criador, grupo, ACL
  - datas (criação, acesso, escrita)
  - permissões
  - tamanho
  - localização dos blocos do ficheiro
- Estrutura de directório: relaciona nomes de ficheiros com FCBs

Estruturas de dados em memória

- São importantes para obter eficiência
- Servem de cache de informação em disco
  - com hit rate médio de 85% em BSD UNIX
- Podem ser trazidas para memória ao montar sistema de ficheiros ou abrir ficheiros
- Exemplos:
  - tabela de sistemas de ficheiros montados
  - cache de directórios acedidos recentemente
  - tabela global de ficheiros abertos – contém FCBs
  - tabelas de ficheiros abertos, por processo

Sistemas de ficheiros virtuais

- Virtual File Systems (VFS): implementação de sistema ficheiros orientada por objectos
- Permitem que a mesma interface de chamadas ao sistema (API) seja usada para aceder a diferentes sistemas de ficheiros
- Programas usam interface genérica de sistema de ficheiros
- Interface genérica invoca API do VFS e não de um sistema de ficheiros específico
- Exemplo: permite encapsular um sistema de ficheiros local e um remoto sob a mesma interface

Exemplo de Desenho com VFS

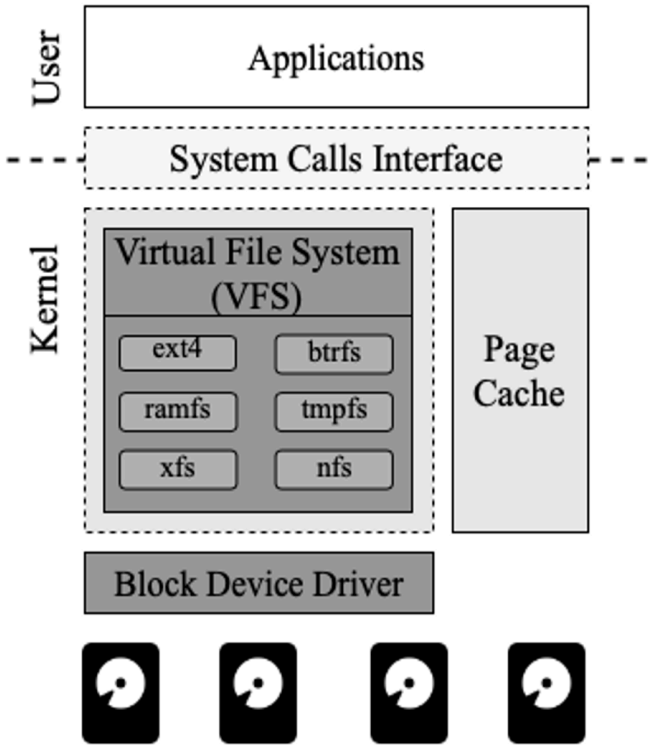

Implementação de directórios

- Lista com nomes de ficheiros e apontadores para blocos
  - simples
  - procura de nome potencialmente demorada
  - lista ordenada facilita procura mas dificulta alterações
- Hash table
  - reduz tempo de procura no directório
  - possibilidade de colisões
  - problema: tamanho fixo da hash table e dependência da função de hash desse tamanho

Alocação de espaço em disco

- Espaço em disco dividido em blocos
- Vários blocos por ficheiro
- Vários métodos para atribuír blocos a ficheiros:
  - contígua
  - lista ligada
  - indexada
- normalmente um sistema de ficheiros usa apenas um método

Contígua

- Cada ficheiro ocupa conjunto contíguo de blocos
- Simples: necessário guardar bloco inicial e tamanho
- Acesso eficiente: p.ex., pouco deslocamento cabeça do disco
- Permite acesso aleatório a ficheiros
- Desperdício de espaço: fragmentação externa
- Ficheiros não podem crescer ou grande fragmentação interna
- Compactação periódica para eliminar fragmentação; custosa
- Variante: alocação por extents
  - um extent é uma sequência contígua de blocos
  - um ficheiro é alocado a um conjunto de extents
  - extents grandes - fragmentação interna
  - extents tamanho variável - fragmentação externa

Lista ligada

- Ficheiro constituído por lista ligada de blocos
- Blocos espalhados pelo disco
- Acesso pouco eficiente: p.ex., deslocamento cabeça do disco
- Viável para acesso sequencial; acesso aleatório muito ineficiente
- Bom uso do espaço: apenas pequena fragmentação interna
- Ficheiros podem crescer sem problema
- Variante: agrupar blocos em clusters e alocar clusters
  - permite lista ligada menor (menos apontadores para blocos)
  - leituras e escritas no disco feitas à granularidade do cluster
    bom para operações grandes, mau para pequenas
  - fragmentação interna quando clusters parcialmente usados

File allocation table (FAT)

- Variante de lista ligada
- Tabela separada com uma entrada por bloco do disco
- Cada ficheiro é representado por uma lista ligada na FAT
- Pode ser feita cache da FAT para aumentar eficiência no acesso
- FAT usada pelo MS-DOS e OS2

FAT: exemplo

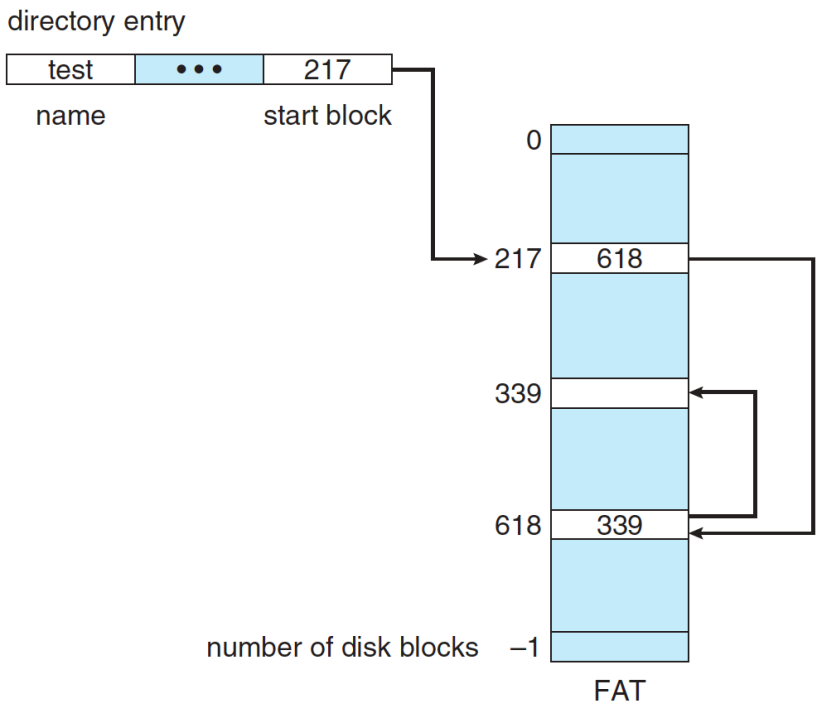
directory entry
test
• • •
217
name
start block
0
217
618
339
618
339
number of disk blocks
–1
FAT

Alocação indexada

- Cada ficheiro tem um index block
- Contém apontadores para blocos; análogo a tabela de páginas
- Acesso aleatório a ficheiros
- Ausência de fragmentação externa
- Problema: tamanho do index block
  - grande – desperdício espaço para ficheiros pequenos
  - pequeno – problema: como guardar ficheiros grandes

Alocação indexada

Como suportar ficheiros grandes:

- lista ligada de index blocks
- indexação multi-nível: hierarquia de index blocks
- esquema misto (e.g. inodes em UNIX):
  - primeiras entradas apontam para blocos;
  - uma entrada para index block;
  - uma entrada para hierarquia de index blocks com 2 níveis;
  - uma entrada para hierarquia de index blocks com 3 níveis;

Exemplo: inode UNIX

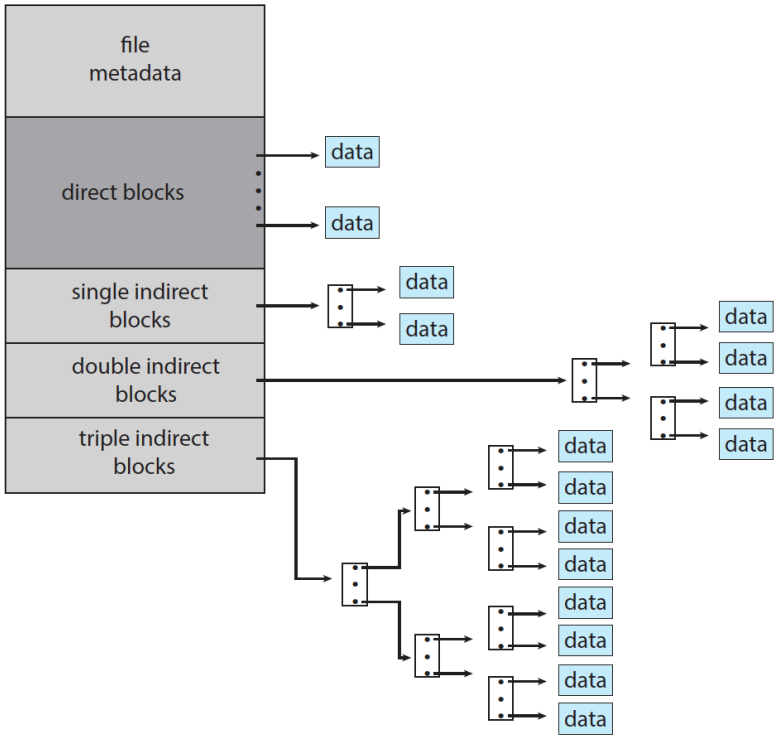

Gestão do espaço livre – bitmap

- bitmap – vector de bits
- Bloco ocupado – bit = 1
- Número de bits = número de blocos em disco
- Fácil localizar espaço livre contíguo:
  - sequências de longs a 0 – 64 blocos livres por long
  - sequências de bytes a 0 – 8 blocos livres por byte
- Bitmap pode ocupar muito espaço; exemplo:
  - tamanho do bloco: 4KB = 2^{12} bytes
  - tamanho do disco: 1TB = 2^{40} bytes
  - número de bits: $2^{40}/2^{12} = 2^{28}$ bits = 32 MB
- Pode demorar tempo a percorrer bitmap e encontrar espaço livre

Gestão do espaço livre – lista ligada

- Lista ligada de blocos livres
- Encontra-se nos próprios blocos – não necessita espaço extra
- Inapropriada para encontrar blocos contíguos
- Imediato encontrar bloco livre – não necessita procura
- FAT usa este mesmo método para blocos livres e ficheiros
- Variante – com agrupamento:
  - bloco livre mantém apontadores para *n* blocos livres
  - o último destes contém outros *n* apontadores
- Variante – contar blocos livres contíguos:
  - cada bloco contém número de blocos livres contíguos à sua frente

Eficiência e desempenho

- Eficiência depende de:
  - algoritmos de alocação de blocos e directórios
  - tipos de metadados na entrada do ficheiro no directório
- Desempenho:
  - cache em memória de blocos de disco
  - cache unificada:
    - para páginas de ficheiros mapeados em memória e
    - blocos de ficheiros acedidos via sistema de ficheiros
    - cache unificada evita double caching; melhora eficiência
    - Política LRU bastante utilizada para substituir blocos na cache
  - read-ahead e free-behind para optimizar acesso sequencial
  - I/O assincrono – nomeadamente escritas

Eficiência e desempenho

- Pre-alocar inodes e espalha-los pelo disco:
  - algum espaço pode ser desperdiçado
  - ideia: tentar manter blocos de um ficheiro perto do seu inode
  - reduz seek time
- Clusters de tamanho variável:
  - agrupamento de blocos em clusters melhora tempo de acesso
  - mas causa fragmentação
  - solução: usar clusters de tamanho variável
  - clusters pequenos para ficheiros pequenos e último cluster de ficheiro

Consistência do sistema de ficheiros

- Dados em memória podem não ser logo gravados em disco
- Se o computador falha, informação pode ser perdida
- Possibilidades:
  - conteúdo de ficheiro perde actualizações
  - sistema de ficheiros fica inconsistente
- Inconsistência de sistema de ficheiros mais grave
- Resulta de invariantes das estruturas de controlo serem violados
- Solução parcial: estruturas de controlo devem ser gravadas sincronamente quando modificadas
- Programas de verificação de consistência comparam estrutura de directórios com blocos no disco e tentam corrigir problemas

Sistemas de ficheiros estruturados por log

- Pretendem evitar corrupções num sistema de ficheiros
- Sistemas de ficheiros log structured ou journaling guardam cada actualização ao sistema de ficheiros como uma transacção
- As transacções são escritas num log
  - uma transacção é committted depois de escrita no log
  - o sistema de ficheiros pode ser actualizado mais tarde
- As transacções no log são aplicadas ao sistema de ficheiros assincronamente
  - quando este é modificado, a transacção é removida do log
- Se há um crash, as transacções restantes do log não se perdem e serão aplicadas mais tarde
- Acesso sequencial ao log melhora desempenho
- Utilizado em vários sistemas de ficheiros atuais (Ext4, ZFS, ...)